

HACKATHON 2021

by L'ÉQUIPE

Qui sommes-nous ?

Une team Made in **Epita Paris**

L'équipe, c'est:

- deux data scientists:

Maxime Leherle

Kévin Guillet

- trois responsables sécurité:

Simon Guiot

Sébastien Lanyi

Vianney Delaboudinière

Challenge 1 - Identifier

Intercepter des signaux sur les capteurs d'énergies:

- Une séquence de touches clavier a été enregistré
- Cette séquence contient des **identifiants** de connexion

Le but est de retrouver les **identifiants** encodés sous forme de **signaux électrique**.

Problématique retenue : Comment extraire le login et le mot de passe depuis les données du rayonnement électrique ?



Travail effectué en amont:

- Pose d'un appareil de mesure électrique (eavesdropping)
- Récupération des signaux dans une plage de fréquences donnée.

Notre solution

Une ressemblance forte à un OCR ...

Tout part de la base de données ...

- On charge les trames associées aux lettres en utilisant le script fourni.
- Ces trames sont chargées et nous en tirons les informations nécessaires afin d'en créer une base de données csv.
- Ce fichier csv contient l'ensemble des trames, avec les touches associées aux 17 pics (1 par colonne), ce qui donne un peu plus de 350.000 lignes.
- Lors de l'entraînement du modèle, on sépare la base de données aléatoirement avec **70%** pour l'entraînement et **30%** pour la validation.

... pour construire un modèle de prédiction ...

Le problème pouvant se rapprocher d'un OCR, nous avons choisi une solution similaire:

- Nous avons utilisé un modèle d'apprentissage supervisé type classifieur linéaire, le **SVM**.
- Cependant nous avons observés des résultats parfois très proche entre touches.
- Nous avons donc testé une approche avec les **probabilités** de chaque touche sur chaque trame pour tester les cas de détection imprécise, cela n'a rien donné. Nous avons également optimisé les prédictions en les **parallélisant**.

... pour retrouver des identifiants.

- On lance la prédiction sur la totalité de la capture découpées en trames de 17 pics.
- La séquence '**CTRL+ALT+SHIFT**' est interprétée comme une séquence commençant par des '**CTRL**' et finissant par des '**NOKEY**' (*l'utilisateur relâche les touches*).
- Puis nous analysons la capture en considérant les séquences d'une même prédiction comme **une seule touche**. Les prédictions sans répétition sont considérées comme du bruit et sont ignorées.

- Résultats finaux -

Prédiction des identifiants:

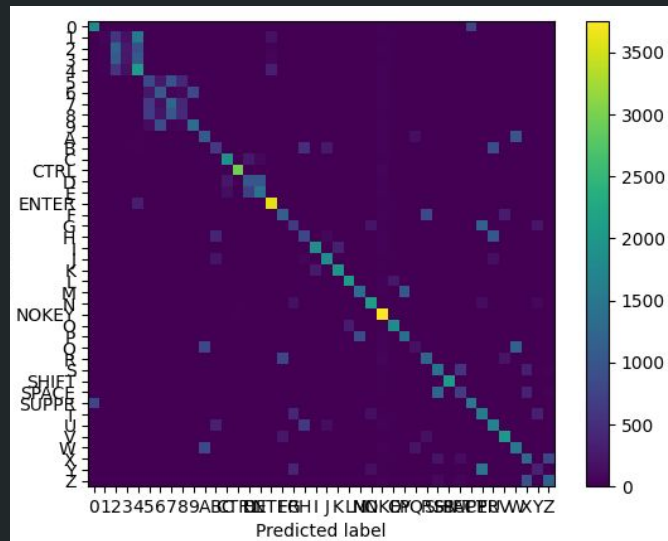
- après traitement, notre algorithme renvoie cette série de touche :

SHIFTISHIFTUAWAWCKAWTGON202244

- nous pouvons supposer que les identifiants sont :

login: Hackathon
mdp: 2022

Entrainement du modèle:



score de validation: 61.05%

Ouverture

Comment gérer le bruit de façon automatisé ?

- Avoir une base de données qui contient les signaux associés à l'appui de **SHIFT+touche** et **CTRL+ALT+SHIFT**.
- Remplacer notre déduction d'identifiants par une **IA** qui :
 - À partir d'une grande quantité de captures dont on connaît les identifiants associés.
 - sur lesquels on lance notre modèle de prédiction d'appui de touches.
 - **détermine les identifiants** à partir de la séquence de touches prédites.